Bewusstsein als semantische Selbstzuschreibung

Entwurf einer sprachlich-reflexiven Minimaltheorie

2026-10-26

Inhalt

1 Abstract und Leitthese **4**
1.1 Zentrale These 5

2 Die begriffliche Ausgangslage: nicht ein Phänomen, sondern viele **6**
2.1 1.1 Die Heterogenität des Ausgangsbegriffs 6
2.2 1.2 Revisionäre Explikation statt Wesensschau 6
2.3 1.3 Vier Dinge, die nicht zusammenfallen 7

3 Sprache, Bedeutung und reflexive Selbstzuschreibung **8**
3.1 2.1 Weshalb die Zeichenfolge nicht genügt 8
3.2 2.2 „Ich“ als indexikalische Selbstreferenz 8
3.3 2.3 Brandom und das Kriterium der Begriffskompetenz 9
3.4 2.4 Die Gefahr, das Rätsel nur zu verschieben 9
3.5 2.5 Der entscheidende begriffliche Übergang 10

4 Eine formale Minimaldefinition **11**
4.1 3.1 Welches Problem soll die Formel lösen? 11
4.2 3.2 Vier Bedingungen statt eines geheimen Prädikats 11
4.3 3.3 Was bedeutet dann „Ich habe Bewusstsein“? 12
4.4 3.4 Drei Ebenen, die nicht ineinander fallen 13
4.5 3.5 Dauer und Ruhe: das Dispositionsproblem 14
4.6 3.6 Logische Reichweite und Carnaps Probe 15

5 Kommunikation, Evidenz und die Reichweite des Selbstnachweises **16**
5.1 4.1 Von der Aussage zum Nachweis: vier getrennte Fragen 16
5.2 4.2 Ein kleiner Satz über einen großen Fehlschluss 16
5.3 4.3 Wann ist ein Bericht ein guter Grund? 17
5.4 4.4 Was selbstbezüglich unfehlbar ist — und was keineswegs 18
5.5 4.5 Warum interne Selbstzuschreibung zählt 18
5.6 4.6 Nicht jeder Selbstbericht ist eine Beobachtung 19
5.7 4.7 Zwischenstand 19

6 Fälle, an denen die Theorie bestehen muss **21**
6.1 5.1 Der Fuchs, der ein „Ich“ erwirbt 21
6.2 5.2 Säugling und Spracherwerb 21
6.3 5.3 Sprachverlust und die Gefangenschaft des Nachweises 21
6.4 5.4 Träumen und die Frage an den Träumenden 22
6.5 5.5 Hegels Tod — und die Fortdauer seiner Bücher 22
6.6 5.6 Das System, das nur einen Satz ausgibt 23

7 Philosophiegeschichtliche Verortung **24**
7.1 6.1 Descartes: Gewissheit im Vollzug 24
7.2 6.2 Kant: Möglichkeit des „Ich denke“ 24
7.3 6.3 Fichte: Selbstsetzung ist mehr als Selbstbericht 25

7.4 6.4 Hegel: Anerkennung und Nicht-Solipsismus . . . 25
7.5 6.5 George Herbert Mead: Die Nähe der internalisierten Kommunikation . . . 25
7.6 6.6 Wittgenstein: Bedeutung ist kein privates Schildchen . . . 26
7.7 6.7 Carnap und Brandom: Methode und semantisches Gerüst . . . 26

8 Verwandte und konkurrierende Positionen 27
8.1 7.1 Phänomenales Erleben: Thomas Nagel . . . 27
8.2 7.2 Zugangsbewusstsein: Ned Block . . . 27
8.3 7.3 Higher-Order-Theorien: Rosenthal und Carruthers . . . 27
8.4 7.4 Phänomenaler Illusionismus: Keith Frankish . . . 28
8.5 7.5 Searle und das Syntax-/Semantik-Problem . . . 28
8.6 7.6 Enaktivismus, Autopoiesis und minimale Agency . . . 28
8.7 7.7 Ein aktueller direkter Einwand: Millière (2025) . . . 29
8.8 7.8 Neurowissenschaftliche Bewusstseinstheorien . . . 29
8.9 7.9 Vergleich auf einen Blick . . . 29

9 Einwände, Gegenmodelle und die Kosten der Explikation 31
9.1 8.1 Bermúdez: Selbstbewusstsein vor dem Wort „ich“ . . . 31
9.2 8.2 Gegenmodell A: semantisch überzeugende Simulation ohne Selbstbezug . . . 31
9.3 8.3 Gegenmodell B: der verstummte kompetente Denker . . . 32
9.4 8.4 Gegenmodell C: empfindungsfähiges, vorsprachliches Tier . . . 32
9.5 8.5 Überinklusion, interne Semantik und regressiver Selbstbezug . . . 32
9.6 8.6 Die Einwände von Perry, Shoemaker und Bar-On . . . 33
9.7 8.7 Wirkliche Widerlegbarkeit . . . 33

10 Empirisches Programm und Forschung bis 2026 35
10.19.1 Forschungslogik . . . 35
10.29.2 Erstperson und Perspektivwechsel . . . 35
10.39.3 Schlaf und Traum . . . 36
10.49.4 Nichtmenschliche Tiere . . . 36
10.59.5 Sprachmodelle und interne Zustandskopplung . . . 36
10.69.6 Jüngere Forschungen und Evidenzstatus . . . 37
10.79.7 Eine unterscheidbare Testvorhersage statt bloßer Beschreibung 38
10.89.8 Welche Beobachtung wäre besonders aufschlussreich? . . . 39

11 Schluss, Quellenkritik und offene Fragen 40
11.110.1 Was die Theorie gewonnen hat . . . 40
11.210.2 Der eigentliche Preis . . . 40
11.310.3 Drei offene Forschungsfragen . . . 41
11.410.4 Quellenkritischer Nachtrag — Verifikationsrunde vom 26. Oktober 2026 . . . 41
11.510.5 Fazit . . . 42

Literatur 43

1 Abstract und Leitthese

Der Ausdruck *Bewusstsein* verweist im philosophischen und gewöhnlichen Sprachgebrauch auf eine heterogene Gruppe von Phänomenen: Wachheit, Wahrnehmung, Aufmerksamkeit, subjektives Erleben, globale Zugänglichkeit von Information, Selbstkenntnis und reflexive Selbstzuschreibung. Die Heterogenität behindert nicht nur den Streit zwischen verschiedenen Theorien, sondern erschwert bereits die Identifikation des Gegenstands. Vorgeschlagen wird deshalb keine weitere Gesamttheorie dieser Phänomene, sondern eine **revisionäre, sprachlich-reflexive Minimaltheorie**.

Ihr Gegenstand ist eine von anderen Leistungen unterscheidbare Eigenschaft: Ein hinreichend individuiertes System ist im Sinn des Explikats `C*` bewusst, wenn es **de-se-Selbstreferenz**[1] beherrscht, seine **eigene Selbstzuschreibungsoperation** zum Gegenstand machen und dieses Urteil **inferenziell verbindlich** verwenden kann. Die Bedingungen werden ohne Rückgriff auf das Wort „Bewusstsein“ formuliert; gleichwohl bleibt ihre unabhängige Operationalisierung ein Forschungsvorhaben. Der gelingende Satz „Ich habe Bewusstsein“ ist nicht wegen seines Wortlauts beweiskräftig, sondern insofern der Akt diese Kompetenzen trägt. Ein Tonband, ein Papagei und ein sprachmächtiges System mit ausschließlich nachgeahmter Selbstzuschreibung bilden deshalb relevante Gegenproben.

Die Theorie unterscheidet **Konstitution**, **Vollzug**, **bloße Zeichenproduktion** und **fehlbaren Fremdnachweis**. Kommunikationsfähigkeit ist kein notwendiger Bestandteil des aktuellen Fortbestands einer bereits intern realisierten Kompetenz; fehlende Mitteilbarkeit bedeutet fehlende intersubjektive Feststellbarkeit, nicht notwendig fehlendes `C*`. Eine zeitindizierte Darstellung vermeidet, dass ein heutiger Nachweis den Bewusstseinszustand der Vergangenheit oder Zukunft garantiert. Der Vorschlag ist im Sinne von Carnaps Explikation zu beurteilen (Carnap 1950), nicht mit dem Anspruch, Nagels subjektiven Erlebnischarakter (Nagel 1974) definitorisch zu widerlegen. Ihre zwei stärksten noch offenen Belastungsproben liegen in einer **nichtzirkulären**

[1] *De se* (lateinisch: „von sich selbst“, „über sich selbst“) bezeichnet den Bezug auf sich **als sich selbst**, also aus der Ich-Perspektive. Wer weiß, dass „Person A beobachtet wird“, weiß damit noch nicht „Ich werde beobachtet“, solange er nicht erkennt, selbst A zu sein. Gemeint ist hier diese erstpersonale Bezugnahme; die reflexive Betrachtung der eigenen Zuschreibungsoperation ist eine zusätzliche Bedingung der Theorie (vgl. Abschnitt 2.2; (Perry 1979; Shoemaker 1968)).

Erklärung semantischer Kompetenz (Bermúdez 1998) und im **zusätzlichen Erklärungsgewinn** gegenüber gewöhnlicher Metasprache, de-se-Referenz und Metakognition. Die Theorie trennt daher einen unter seinen Gelingensbedingungen selbstbeglaubigenden Akt von einem beobachteten Satz, der als Evidenz stets fehlbar bleibt (Shoemaker 1968; Bar-On 2004).

Schlüsselwörter: Bewusstsein, Selbstbewusstsein, Selbstzuschreibung, Sprachphilosophie, Semantik, Explikation, de se, Inferentialismus, künstliche Intelligenz.

1.1 Zentrale These

> Bewusstsein im hier vorgeschlagenen minimalen Sinn ist die gegenwärtig organisierte Fähigkeit eines individuierten Systems, **sich selbst als Träger einer eigenen semantischen Selbstzuschreibungsoperation zu erfassen und diese Einsicht begrifflich verbindlich zu verwenden**. Eine genuine Selbstzuschreibung manifestiert diese Fähigkeit; ihr beobachtbarer Wortlaut allein beweist sie nicht.

Die These nimmt den kommunikativen Akt ernst, aber sie verwechselt ihn nicht mit dem akustischen Ereignis. Der Begriff bleibt bewusst schmal: Wer `C*` hat, muss nicht klug, empfindungsfähig, autonom, moralisch achtenswert oder in Nagels Sinn phänomenal bewusst sein. Diese Negationen sind **Nichtimplikationen**, keine Behauptungen des jeweiligen Gegenteils.

2 Die begriffliche Ausgangslage: nicht ein Phänomen, sondern viele

2.1 1.1 Die Heterogenität des Ausgangsbegriffs

Bewusstsein lässt sich im gewöhnlichen Gebrauch einer Person beim hellwachen, konzentrierten Nachdenken zusprechen; zugleich soll es in einem Tagtraum, einem lebhaften nächtlichen Traum, einem Schmerz oder einem beiläufig wahrgenommenen Geräusch vorliegen. Andere Beschreibungen lassen Bewusstsein im tiefen Schlaf fehlen, obwohl die Person offenbar nicht aufhört, Sprache zu beherrschen. Wieder andere identifizieren es fast mit Intelligenz oder der Fähigkeit, sich selbst als Handelnden zu erkennen.

Diese Verwendungen sind nicht bloß unterschiedliche Intensitätsgrade einer gesicherten Größe. Sie unterscheiden sich in ihrem **logischen Gegenstand**. Manche betreffen den Zustand eines Organismus, andere den Zugang zu einem Inhalt, wieder andere einen Erlebnischarakter und schließlich die Fähigkeit, sich selbst ein Prädikat zuzuschreiben. Block trennt vor allem phänomenales Bewusstsein (`P-consciousness`) vom funktional beschriebenen Zugangsbewusstsein (`A-consciousness`) (Block 1995). Damit liegt kein allgemeiner Nachweis vor, dass alle Bewusstseinsphänomene auf ein gemeinsames Merkmal zurückgehen.

Die im Dialog entwickelte Kritik ist methodisch: Versteht eine Position Bewusstsein gerade als die maximale Konzentration und eine andere als unbefangenen Gedankenfluss, so kann eine Definition nicht beide Beschreibungen unbesehen als dieselbe entscheidende Eigenschaft übernehmen. Ein bloßes Nebeneinander widerstreitender Intuitionen ist noch keine konsistente Theorie.

2.2 1.2 Revisionäre Explikation statt Wesensschau

Carnaps Vorschlag zur *Explikation* unterscheidet den erklärungsbedürftigen Ausgangsbegriff (*explicandum*) vom präziseren Ersatzbegriff (*explicatum*).[1]

[1] Explikation ist hier keine bloße Wörterbucherklärung. Der Ersatzbegriff darf vom bisherigen Sprachgebrauch abweichen; gerade deshalb muss eigens begründet werden, welche Unterscheidungen und Untersuchungen er ermöglicht. Eine Definition allein entscheidet noch nicht, welche Lebewesen oder Systeme die definierte Eigenschaft tatsächlich besitzen.

Eine Explikation darf alte Grenzfälle neu zuordnen, muss sich aber unter anderem an Ähnlichkeit, Exaktheit, Fruchtbarkeit und Einfachheit messen lassen (Carnap 1950). Unser C* soll also **nicht** durch rhetorische Umbenennung beweisen, dass die bisherige Bewusstseinsdiskussion gegenstandslos sei.

Sein Nutzen muss in eigenständigen Konsequenzen liegen: eine stabile Trennung zwischen Besitz und Erweis, eine überprüfbare Semantikbedingung, eine klare Zeitindizierung und die Vermeidung unbegründeter Rückschlüsse auf Schmerz, Intelligenz oder moralischen Status. Der Preis liegt ebenso offen: Ein Tier, ein Säugling oder eine Person mit gravierenden kognitiven Einschränkungen könnte empfindungsfähig sein, ohne die definierte Eigenschaft zu besitzen. Wo der übliche Ausdruck anderes nahelegt, ist der **revisionäre Charakter** auszuweisen und nicht zu kaschieren.

2.3 1.3 Vier Dinge, die nicht zusammenfallen

Zu unterscheiden sind:

1. **Erlebnis**: Ein Zustand besitzt möglicherweise einen subjektiven Charakter, etwa das Schmerzhafte des Schmerzes (Nagel 1974).
2. **Zugang**: Ein Inhalt ist für Überlegungen, Berichte oder flexible Handlungssteuerung verwendbar (Block 1995).
3. **Reflexive Kompetenz**: Das System kann die eigene gegenwärtige kognitive Zuständigkeit unter einem Begriff thematisieren.
4. **Kommunikativer Nachweis**: Ein anderer Beobachter erhält relevante, hinreichend authentifizierte Evidenz dieser Kompetenz.

Das Minimalprogramm betrifft ausdrücklich den dritten Punkt; der vierte ist seine bevorzugte Untersuchungsmethode. Weder (1) noch (2) werden dabei für nichtexistent erklärt. Die Theorie soll das Bewusstseinsproblem nicht in einem einzigen Satz auflösen, sondern eine klar explizierbare Teilfrage aus einem überladenen Begriffsverband herauslösen.

3 Sprache, Bedeutung und reflexive Selbstzuschreibung

3.1 2.1 Weshalb die Zeichenfolge nicht genügt

Das aufgedruckte „Ich habe Bewusstsein“ beweist nichts über das Papier. Ein Tonband kann es abspielen; ein Papagei kann es aussprechen, ohne notwendig die Bedeutung zu erfassen. Die Frage lautet daher nicht, ob ein System das Token[1] erzeugt, sondern **wessen semantischer Akt** stattfindet und welche Kompetenzen ihn tragen.

Searles *Chinese Room* illustriert den Einwand gegen die vorschnelle Identifikation von formal korrekter Symbolverarbeitung mit Verstehen (Searle 1980). Allerdings ist das Gedankenexperiment selbst keine allgemeingültige Widerlegung funktionaler Semantik: Ein System könnte durchaus durch seine verteilte Architektur, seinen Weltbezug und sein korrigierbares Handeln Bedeutungen realisieren, auch wenn einzelne Bestandteile nur formale Operationen ausführen. Die Minimaltheorie darf weder den Papagei einschließen noch Searles weitergehenden biologischen Naturalismus ungeprüft voraussetzen.

3.2 2.2 „Ich“ als indexikalische Selbstreferenz

Der Begriff *de se* bezeichnet eine erstpersonale Weise des Bezugs, die nicht bereits durch die zufällige Identifizierung eines Objekts — welches man selbst ist — erschöpft wird. Angenommen, jemand liest „Person A wird beobachtet“, ohne zu wissen, selbst A zu sein. Der Erwerb der Information „**Ich** werde beobachtet“ kann seine Schlüsse und Handlungen verändern, obwohl die referierte Person dieselbe bleibt. Perry zeigt, warum diese *essentielle Indexikalität* für die Erklärung von Handlungen unverzichtbar sein kann (Perry 1979); Shoemaker beschreibt Fälle, in denen ein erstpersonales Urteil gegen **Fehlidentifikation des Subjekts**, nicht aber gegen alle inhaltlichen Fehler

[1] Ein *Token* ist ein einzelnes Vorkommnis eines Zeichens oder Ausdrucks; der *Typ* ist die wiederholbare Zeichenform. Zwei Aufnahmen des Satzes „Ich habe Bewusstsein“ können denselben Satztyp wiedergeben, ohne dass das jeweilige Abspielgerät damit eine eigene Behauptung aufstellt.

geschützt ist (Shoemaker 1968). Nichtbegriffliche Formen des Selbstbezugs bleiben eine gesonderte Frage (Bermúdez 1998; Sebastián 2020).

Eine genuine Selbstzuschreibung setzt daher mindestens voraus, dass das System die eigene Sprecher-/Akteursposition flexibel von anderen unterscheidet, einen Wechsel der Sprecherposition begreift und denselben erstpersonalen Bezug in neuen Situationen verwendet. **Dieser Nachweis de-se-fähiger Indexikalität allein ist jedoch noch kein Nachweis unserer stärkeren reflexiven Kompetenz**: Selbstreferenz ist ein notwendiger Teil der Minimaltheorie, nicht ihr gesamter Gegenstand. Es muss nicht das deutsche Wort `ich` oder überhaupt Lautsprache verwenden: Schrift, Gebärden, maschinelle Symbole und eine hypothetische Fuchssprache können prinzipiell dieselbe Rolle übernehmen.

3.3 2.3 Brandom und das Kriterium der Begriffskompetenz

Inferentialistische Semantik[2] bietet eine positive Alternative zur Gleichsetzung von Bedeutung und Zeichenfolge. Für Brandom hängt die Beherrschung eines Begriffs an der Fähigkeit, mit Behauptungen regelhaft Verpflichtungen, Berechtigungen, Folgerungen und Unvereinbarkeiten zu handhaben (Brandom 1994). Die bloße zuverlässige Reaktion „rot“ auf rote Flächen genügt in einem solchen Modell noch nicht.

Für `C*` sind insbesondere folgende Aufgaben relevant: Eine Person muss ihre jetzige Selbstzuschreibung von einer früheren unterscheiden, fremde Selbstberichte richtig als fremde behandeln, begründete Gegenbeispiele in die Anwendung aufnehmen, widersprüchliche Behauptungen erkennen und die eigene Aussage unter neuen Bedingungen revidieren können. Diese Kriterien werden **hier vorgeschlagen**; sie sind keine wörtliche Bewusstseinsdefinition Brandoms.

3.4 2.4 Die Gefahr, das Rätsel nur zu verschieben

Die Bedingung „semantisch genuin“ darf nicht als verborgener Ehrentitel fungieren. Wenn wir sie immer genau den Systemen zusprechen, denen wir bereits Bewusstsein unterstellen, entstünde ein definitorischer Kreis. Die Theorie benötigt deshalb **kontrastive, falsifizierbare Arbeitskriterien**: Können generalisierte Inferenzen, Korrekturen, Perspektivwechsel und kausale

[2] *Inferenziell* heißt: die Folgerungen einer Aussage und ihre Beziehungen zu anderen Aussagen betreffend. Wer etwa „Ich habe diese Behauptung aufgestellt“ bejaht, kann nicht zugleich ohne weitere Erklärung „Niemand hat diese Behauptung aufgestellt“ behaupten. „Verbindlichkeit“ meint hier solche begrifflichen Festlegungen und Korrekturanforderungen, keine moralische Verpflichtung.

Beziehungen zwischen eigenen Zuständen und Selbsturteilen unabhängig von der Erwähnung des Wortes „Bewusstsein“ nachgewiesen werden?

Das ist keine abschließende Lösung des *symbol-grounding problem*. Besonders Searle und Bermúdez markieren offene Schwierigkeiten (Searle 1980; Bermúdez 1998). Doch genau hier liegt die belastbare Forschungsaufgabe: *Was unterscheidet semantisch geleitete Selbstprädikation von erfolgreicher Imitation?*

3.5 2.5 Der entscheidende begriffliche Übergang

Zwischen dem Satz „Ich spreche“ und „Ich weiß, dass ich mich mit *ich* selbst als Sprecher bezeichne“ liegt ein strukturierter Übergang. Der zweite Satz hat **die Selbstzuschreibungsoperation des ersten** zum Gegenstand. Diese Reflexivität lässt sich im Prinzip nach seinen **begrifflichen Folgen** untersuchen: Kann das System angeben, wer in einem Sprecherwechsel auf sich selbst verweist? Kann es erkennen, dass ein gespeicherter Ich-Satz nach dem Abspielen nicht plötzlich **vom Abspielgerät** verfasst wurde? Kann es sich bei einem Perspektivfehler korrigieren?

Die Minimaltheorie schlägt vor, genau diese Fähigkeit als `C*` zu benennen. Ihr Inhalt ist dadurch nicht selbstreferenziell im schlechten Sinn einer Definition, die „Bewusstsein ist Zuschreibung von Bewusstsein“ lautet, sondern beschreibt eine Operation an **anderen, unabhängig verständlichen** semantischen Akten. Allerdings ist die Wahl des Namens „Bewusstsein“ eine **begründungsbedürftige Explikation** und keine begriffliche Zwangsläufigkeit. Der Begründung dient die eigenständige Fruchtbarkeitsprüfung in §3.6.

4 Eine formale Minimaldefinition

4.1 3.1 Welches Problem soll die Formel lösen?

Die ursprüngliche Leitformel — „bewusst ist, wer sich Bewusstsein zuschreiben kann“ — besitzt einen erheblichen Vorzug: Sie macht aus der Frage nach einem vermeintlich unsichtbaren Ding eine Frage nach einer bestimmbaren Kompetenz. Aber in ihrer nackten Form ist sie zirkulär. Wer die Bedeutung des Wortes *Bewusstsein* erst durch dessen kompetente Selbstzuschreibung erklären will, darf die Kompetenz nicht bereits als das Erkennen eigenen Bewusstseins bestimmen.

Deshalb soll die folgende Rekonstruktion **zuerst eine Leistung ohne das Wort „Bewusstsein“ beschreiben**. Erst anschließend erhält diese Leistung den Namen *sprachlich-reflexives Bewusstsein* (hier: `C*`). Das ist eine Begriffsexplikation im Sinne Carnaps, keine Ableitung der gesamten Psychologie aus Logik (Carnap 1950). Unsere Definition ist erfolgreich, wenn die zunächst unabhängig beschriebene Leistung wirklich identifizierbar ist und der neue Begriff mehr theoretische Arbeit leistet als seine Bestandteile.

4.2 3.2 Vier Bedingungen statt eines geheimen Prädikats

Sei `x` ein zu einer Zeit `t` abgrenzbarer funktionaler Prozesszusammenhang. In der folgenden Notation bedeutet *fähig* nicht „sagt gerade den Satz“, sondern: Die gegenwärtige Organisation besitzt die betreffende Disposition[1]; ob sie mobilisierbar ist, wird in §3.5 erläutert.

I — Individuation: Wir können einen Träger des Vorgangs von Werkzeugen, Zitaten und bloßen Übertragungsmedien unterscheiden. Zu klären ist, **welches System** als Urheber einer selbstbezüglichen Leistung zählt; biologische Selbsterhaltung wird nicht vorausgesetzt.

[1] Eine Disposition ist eine gegenwärtig vorhandene Fähigkeit, die nicht ständig ausgeübt werden muss: Wer gerade schweigt, kann dennoch sprechen können. Das Beispiel erläutert nur die Unterscheidung zwischen Fähigkeitsbesitz und Ausübung; welche Bedingungen die reflexive Kompetenz im Schlaf oder nach einer Schädigung erhalten, muss gesondert untersucht werden.

D — de-se-Referenz: `x` kann einen Ausdruck oder eine funktionsäquivalente Operation beherrschen, die auf `x` *als sich selbst* verweist. Es kennt nicht bloß einen Namen des Objekts `x`, sondern unterscheidet die Sprecherposition von der Position anderer. Dass diese Art des Bezugs eine eigenständige Rolle spielt, zeigen Perrys Analysen des *essential indexical* (Perry 1979) und die Diskussion erstpersonaler Fehlidentifikation bei Shoemaker (Shoemaker 1968).

M — reflexive Anwendung: `x` kann **seine eigene Selbstreferenzoperation** zum Gegenstand einer weiteren Aussage machen. Das ist mehr als „Ich bin hungrig“: Das System kann etwa unterscheiden zwischen „Der Satz behauptet etwas über einen anderen“ und „Mit diesem Satz mache *ich* eine Aussage über mich“; es kann sich als den Träger eben dieses Bezugs behandeln. Der Inhalt ist also an unabhängig beschreibbare sprachliche bzw. repräsentationale **Operationen** gebunden, nicht an eine bereits vorausgesetzte mysteriöse Bewusstseinseigenschaft.

V — semantische Verbindlichkeit: Diese Unterscheidungen haben Folgen für die Verwendung weiterer Aussagen. Perspektivwechsel, Widersprüche und Korrekturen ändern die inferenziellen Festlegungen des Systems. Das ist stärker als das Reproduzieren einer Passage, verlangt aber keine unfehlbare Selbsterkenntnis und keine selbstgesetzten Lebensziele. Brandoms inferentialistisches Vokabular liefert hierfür ein mögliches, nicht unumstrittenes Modell (Brandom 1994).

Damit ist die vorgeschlagene Definition:

$$C^*(x,t) \iff I(x,t) \wedge D(x,t) \wedge M(x,t) \wedge V(x,t).$$

Die Bedingungen `D`, `M` und `V` sprechen **nicht** vom Vorliegen von `C*`. Man kann ihr Funktionieren an den von ihnen ermöglichten Unterscheidungen beschreiben und erst *danach* fragen, ob die Konjunktion erfüllt ist. Das beseitigt die offensichtliche **lexikalische Zirkularität**, aber nicht automatisch jedes Problem genuiner Semantik. Ob unabhängige Kriterien die Kompetenzen tatsächlich vollständig erfassen, bleibt offen.

4.3 3.3 Was bedeutet dann „Ich habe Bewusstsein“?

Wenn `C*` als Abkürzung der obigen Konjunktion eingeführt ist, lässt sich der Satz semantisch erläutern, ohne auf ein angeblich im Kopf gefundenes Ding zu zeigen:

Dieses System kann in einer begrifflich verbindlichen Weise von sich selbst sprechen und dabei seine eigene erstpersonale Zuschreibungsoperation als eine Operation dieses Systems behandeln.

Ein Sprecher muss die philosophische Definition **nicht wörtlich auswendig kennen**. Er muss ihre relevanten Unterscheidungen in seinem eigenen begrifflichen System beherrschen. Eine andere Sprache kann denselben semantischen Gehalt ausdrücken, ohne ein Wort zu besitzen, das unserem „Bewusstsein“ morphologisch ähnelt.

Die Beherrschung des bloßen Pronomens „ich“ reicht deshalb **noch nicht**: Jemand kann ohne erkennbare Probleme „Ich will Wasser“ sagen, ohne damit schon die eigene Fähigkeit zur reflexiven Selbstzuschreibung begrifflich zu thematisieren. Ebenso kann eine Person eine Definition aufsagen, ohne sie de se auf sich anwenden zu können. Dieser Ausschluss ist kein Hinweis auf verborgenes Erleben, sondern eine Forderung an die **Struktur des verwendeten Begriffs**.

Diese Beschränkung macht `C*` zu einer spezielleren Eigenschaft als minimale Selbstunterscheidung. Bermúdez' Argumente für nichtbegriffliche Selbstbewusstseinsformen bleiben davon unberührt (Bermúdez 1998).

4.4 3.4 Drei Ebenen, die nicht ineinander fallen

Für das weitere Argument unterscheiden wir:

Ebene	Symbol	Frage
Konstitutive Organisation	`C*(x,t)`	Besitzt `x` zu `t` die Bedingungen `I,D,M,V`?
Gelungene Selbstzuschreibung	`A(x,t)`	Vollzieht `x` diese Operation gerade tatsächlich, intern oder kommunikativ?
Beobachtbares Zeichen	`U(x,t)`	Wird die entsprechende Zeichenfolge produziert?

Ein bloßes Token ist weder begriffsnotwendig noch begriffshinreichend:

$$U(x,t) \not\Rightarrow C^*(x,t), \qquad C^*(x,t) \not\Rightarrow U(x,t).$$

Ein **genuiner Vollzug** von `A` dagegen verwendet die eben spezifizierten Fähigkeiten. Nach *dieser Definition* gilt daher `A(x,t) \Rightarrow C^*(x,t)`. **Genau darin** liegt der begrenzte Selbstbeglaubigungsanspruch der Theorie — nicht in einer magischen Wirkung der Zeichenfolge. Ob ein beobachtetes `U` wirklich ein `A` ist, stellt die empirische, grundsätzlich fehlbare Erkenntnisfrage dar (§4).

Die formale Notation leistet hier nur, was ihre Voraussetzungen zulassen. Sie beweist weder, dass ein spezifischer Mensch gerade `C*` besitzt, noch, dass ein künstliches System mit demselben Verhalten notwendig dieselbe interne Organisation hat.

4.5 3.5 Dauer und Ruhe: das Dispositionsproblem

Wir benötigen zwei Prädikate, nicht zwei ontologische Bewusstseinsarten:

- `C*_disp(x,t)`: Die aktuell **fortbestehende funktionale Organisation** von `x` umfasst `I,D,M,V`; ihre Operation kann unter gewöhnlichen Erhaltungs- oder Reaktivierungsbedingungen verfügbar werden.
- `C*_akt(x,t)`: `x` übt `D,M,V` zu diesem Zeitpunkt tatsächlich reflexiv aus.

Die bevorzugte Definition des Projekts ist **dispositionell**: `C*(x,t) := C*_disp(x,t)`. Dann gilt:

$$C^*_{akt}(x,t) \Rightarrow C^*(x,t), \qquad C^*(x,t) \not\Rightarrow C^*_{akt}(x,t).$$

Die Konzession an Dispositionen ist keine Trickserei, sondern dieselbe methodische Unterscheidung, die auch bei Sprachbeherrschung oder mathematischen Kenntnissen erforderlich ist: Schlafende müssen nicht sprechen, um ihre Sprache weiterhin zu beherrschen. Gleichwohl zählt eine **irreversibel zerstörte** Struktur nicht als aktuell vorhandene Kompetenz, nur weil sie früher existierte.

Offene Grenze: „Unter gewöhnlichen Reaktivierungsbedingungen“ ist bislang kein präziser neurobiologischer Schwellenwert. Tiefschlaf, Anästhesie und Reanimation fordern hier eine eigenständige Theorie funktionaler Persistenz. Wer statt dessen `C*_akt` „Bewusstsein“ nennen möchte, kann das konsistent tun, entscheidet sich aber **für einen anderen Begriff**. Der Bericht über eine luzide Traumszene testet eher Aktualisierung als den dispositionellen Besitz.

4.6 3.6 Logische Reichweite und Carnaps Probe

Aus der Definition folgt nicht:

$$C^*(x,t) \Rightarrow \text{Sentienz}(x,t) \quad \text{oder} \quad C^*(x,t) \Rightarrow \text{PConscious}(x,t).$$

Hier wird eine **Nichtableitbarkeit aus den Axiomen**, keine empirisch bewiesene Trennung behauptet. Die Theorie verbietet auch nicht, dass weitere Forschungen beide Größen verbinden.

Ein scharfes Gegenargument lautet: Haben wir bloß **Metasprache über ein Selbstmodell** in „Bewusstsein“ umbenannt? Die Antwort kann nicht heißen, die neue Formel sei konsistent. Nach Carnap zählen Ähnlichkeit mit dem gewählten Ausgangsgebrauch, Exaktheit, Einfachheit — vor allem aber **Fruchtbarkeit** (Carnap 1950). Daher muss `C*` künftig unterscheidbare Fälle ordnen, falsch-positive Selbstberichte vermeiden und gegenüber bloßer Pronomenbeherrschung oder allgemeiner Metakognition einen Erklärungsgewinn zeigen. Dies ist der noch nicht erbrachte **substantielle Beweislastteil** der Minimaltheorie.

5 Kommunikation, Evidenz und die Reichweite des Selbstnachweises

5.1 4.1 Von der Aussage zum Nachweis: vier getrennte Fragen

Die Wendung „Ich habe Bewusstsein“ kann auf vier Weisen betrachtet werden, die in einem Argument nicht vertauscht werden dürfen.

Zeichen: Es werden Laute oder Schriftzeichen erzeugt. Ein Tonband kann das ebenso tun wie ein sprachkompetenter Mensch.

Gehalt: Der Satz hat einen erstpersonalen, reflexiven Sinn; dafür muss seine Anwendung mit einer **bestimmten** semantischen Praxis verbunden sein.

Vollzug: Ein konkreter Träger vollzieht die Selbstzuschreibung als *seinen eigenen* semantischen Akt — statt bloß die Worte eines anderen wiederzugeben.

Evidenz: Ein Beobachter hat Grund, gerade diesen Gehalt und Vollzug dem beobachteten Träger zuzuschreiben.

Die oft überzeugende Intuition, die Behauptung selbst **erweise** das Bewusstsein, ist nur auf der **Vollzugsebene** unproblematisch. Denn ein wirklich in unserem Sinne gelungener Selbstzuschreibungsakt `A(x,t)` setzt die konstitutiven Kompetenzen voraus und demonstriert sie *im Vollzug*. Aber genau das zusätzliche Adjektiv **gelungen** muss unabhängig von bloßer Zeichenproduktion begründet werden.

5.2 4.2 Ein kleiner Satz über einen großen Fehlschluss

Aus §3 ergibt sich definitionsgemäß:

$$A(x,t) \Rightarrow C^*(x,t).$$

Aus einer beobachteten Zeichenfolge `U` ergibt sich dagegen **nicht**:

$$U(x,t) \Rightarrow C^*(x,t).$$

Wer einen „definitiven Nachweis“ ankündigt, indem er ein beobachtetes U einfach zum genuinen A erklärt, hat bereits **in die Prämisse hineingeschrieben, was erst erwiesen werden sollte**. Dies wäre ein verdeckter petitio-principii-Fehler, nicht die Stärke der Theorie.

Wir benötigen ein gesondertes Prädikat W_y(x,t): *Der Beobachter y besitzt aufgrund einer transparenten Prüfpraxis hinreichende Gründe für C*(x,t)*. Weil solche Diagnosen fehlbar sind, ist W_y **nicht faktiv**.[1] Die Gleichung

$$W_y(x,t) \Rightarrow C^*(x,t)$$

ist **kein Theorem**. Ein sogenannter *faktiver Nachweis* N_y könnte zwar durch Definition nur dann vorliegen, wenn C* wirklich vorliegt — aber die Schlussfolgerung N_y\Rightarrow C* wäre dann analytisch und keine empirische Absicherung des konkreten Tests.

Unsere präzisierte Aussage ist bescheidener, aber belastbarer: Eine genuine Selbstzuschreibung ist **konstitutiv überzeugend**, ein beobachteter Bericht dagegen nur so gut wie die Gründe, ihn für genuin zu halten. Über die **Stärke** dieser Gründe müssen die Tests entscheiden.

5.3 4.3 Wann ist ein Bericht ein guter Grund?

Ein Einzelzitat besitzt geringe diagnostische Kraft: Ein auf C* positiv getesteter Mensch und ein bloßer Rekorder produzieren denselben Satz. Dagegen kann ein kontrollierter Test Evidenz liefern, wenn seine Ergebnisse unter der Hypothese vorhandener reflexiver Kompetenz wahrscheinlicher sind als unter der Hypothese bloßer Imitation.

Formal für ein zuvor festgelegtes Testresultat E:

$$O_{\text{nach}} = L \cdot O_{\text{vor}}.$$

Dabei bezeichnen die beiden Größen O die **Wettchancen für C* gegenüber seiner Verneinung** vor und nach Beobachtung von E; L ist das Verhältnis der Wahrscheinlichkeit von E bei vorhandenem C* zur Wahrscheinlichkeit von E bei fehlendem C*. Das ist **keine Messformel für Bewusstsein**; ohne empirisch gerechtfertigte bedingte Wahrscheinlichkeiten und Grundraten ist sie nur ein Schema zur Klarstellung der Beweislast. Ihre Pointe ist: Die Überzeugungskraft

[1] *Faktiv* heißt hier: Die Wahrheit des zugeschriebenen Inhalts ist vorausgesetzt oder folgt aus der Zuschreibung. Aus „Jemand weiß, dass p“ folgt in diesem Sinn, dass p wahr ist; aus „Jemand hat gute Gründe für p“ folgt dies nicht. Das Prädikat W_y bezeichnet die zweite, fehlbare Art der Absicherung.

eines Selbstberichts entsteht **im Vergleich möglicher Erklärungen** und nicht aus der Würde des Satzes. Ein Papagei, der den Selbstsatz korrekt zitiert, liefert gegenüber der Imitationshypothese wenig oder keine Evidenz.

Ein prinzipiell taugliches Untersuchungsdesign muss darum kontrollierte **Sprecherwechsel, neue Selbst-/Fremdbezüge, kontrafaktische Szenarien, Fehlzuschreibungen und sinnvolle Korrekturen** einschließen. Bei maschinellen Trägern werden kontrollierte Eingriffe in interne Zustände besonders interessant; entscheidend ist, dass darauf folgende Selbstberichte nachprüfbar zwischen **eigenen und fremden, tatsächlich vorliegenden und nur suggerierten** Zuständen unterscheiden. Auch ein solches Experiment ist nicht unfehlbar, aber ein eigenständiger Evidenzgewinn gegenüber reinem Output-Scoring.

5.4 4.4 Was selbstbezüglich unfehlbar ist — und was keineswegs

Descartes verankert in Meditation II das `ego sum, ego existo` an den jeweiligen Denk- oder Äußerungsvollzug (Descartes 1641). Das ist ein bedeutsames Vorbild für **vollzugsrelative Geltung**, aber kein Freibrief für jedes Ich-Urteil. Bei Shoemaker wird zudem deutlich, dass bestimmte erstpersonale Urteile zwar **gegen eine Fehlidentifikation des Subjekts** geschützt sein können, damit aber nicht in ihrem **zugeschriebenen Prädikat** unfehlbar sind (Shoemaker 1968).

Beispiel: Wer aus dem eigenen Erleben urteilt „Ich bin ängstlich“, kann in diesem Modus gewöhnlich nicht die **andere Person** mit sich verwechseln; er kann sich dennoch **über die Angst** täuschen. In unserer Begriffsexplikation zeigt ein gelungener Akt das Bestehen von `C*` nur wegen seiner **definierten Konstitutionsbedingungen**. Er beweist nicht gleichzeitig jede weitere Selbstaussage.

Damit ist auch eine angebliche pragmatische Selbstwiderlegung eingeschränkt: „Ich habe kein `C*`“ kann aus dem Munde eines genuin reflexiven Sprechers selbstwiderlegend sein — aus dem Lautsprecher eines Vorlesegeräts nicht. **Nicht die Negation, sondern die kompetente Urheberschaft** erzeugt die Spannung.

5.5 4.5 Warum interne Selbstzuschreibung zählt

Die zuerst diskutierte radikale Variante behauptete, Bewusstsein werde **erst mit öffentlicher Äußerung** instituiert. Sie kann den Menschen nicht erklären, der nach einem Unfall jede Kommunikation verliert, aber intern weiterhin die semantische Selbstzuschreibung vollzieht. Die konsolidierte Theorie ersetzt deshalb den **öffentlichen Akt als Existenzbedingung** durch die **gegenwärtige**

Organisation der Fähigkeit (§3.5). Der öffentliche Akt wird zum möglichen **Erkenntnisweg**.

Das entschärft nicht die Bedeutung der Kommunikation. Semantische Praktiken könnten erst durch Interaktion erworben werden; ein gelernter Begriff kann aber auch in Abwesenheit eines aktuellen Gesprächspartners intern verwendet werden. Hier sind der sozial erworbene Maßstab der Korrektheit und die jeweils gegenwärtige Existenz eines anderen Menschen verschiedene Dinge. Mead und Wittgenstein liefern unterschiedliche, jeweils einschlägige Ressourcen für diese Unterscheidung (Mead 1934; Wittgenstein 1953).

Der Satz **„Wer Bewusstsein hat, muss es nicht nachweisen“** enthält deshalb keinen Scheinwiderspruch. Ein Sachverhalt ist nicht dadurch aufgehoben, dass einem Beobachter jeder Zugriff auf ihn fehlt. Die empirische Kehrseite muss aber gleich ernst genommen werden: **Fehlender Nachweis erlaubt weder sichere Verneinung noch sichere Zuschreibung.**

5.6 4.6 Nicht jeder Selbstbericht ist eine Beobachtung

Dorit Bar-On behandelt *avowals*, erstpersonale Äußerungen wie „Ich bin besorgt“ oder „Ich glaube, dass …“, nicht bloß als Berichte über ein zuvor inspiziertes inneres Objekt, sondern als spezifische **Ausdruckshandlungen**; sie diskutiert gleichzeitig ihre Wahrheitsfähigkeit und besondere erstpersonale Autorität (Bar-On 2004). Diese Position steht unserer Motivlage sehr nahe, zwingt aber eine zusätzliche Unterscheidung auf: **etwas ausdrücken, etwas berichten und dadurch etwas konstituieren sind drei verschiedene Behauptungen**.

Dass eine sprachliche Selbstzuschreibung die kompetente Selbstbeziehung *manifestieren* kann, bedeutet noch nicht, dass jeder durch sie ausgedrückte Zustand **erst durch das Sprechen** entsteht. Unsere These ist insofern keine allgemeine Theorie performativer Erzeugung psychischer Zustände. Austins Sprechakttheorie zeigt, dass bestimmte Akte institutionelle Tatbestände schaffen können; die entsprechenden Gelingensbedingungen müssen jeweils **für genau diesen Akt** ausgewiesen werden (Austin 1962).

5.7 4.7 Zwischenstand

Die Formulierung des Gesprächs — *Bewusstsein ist die abstrakte Eigenschaft, die durch die semantisch kompetente Selbstzuschreibung konstituiert wird* —

bleibt in einer präzisierten Hinsicht erhalten. **Konstituierend** ist die funktional vorhandene reflexive Kompetenz; **realisierend** kann ein innerer oder äußerer Vollzug sein; **nachweisend** ist ein unter prüfbaren Bedingungen als genuin identifizierter Akt. Kein zusätzlicher „Trick“ inneren Erlebens wird für `C*` vorausgesetzt. Ebenso wenig werden die Grenzen der Fremderkenntnis per Definition abgeschafft.

6 Fälle, an denen die Theorie bestehen muss

6.1 5.1 Der Fuchs, der ein „Ich“ erwirbt

Man stelle sich einen Fuchs mit einer symbolischen Sprache vor, die in fremde und eigene Perspektiven unterscheiden lässt. Die bloße Einführung eines Tokens, das wir mit „ich“ übersetzen, genügt nicht: Er muss dessen indexikalische Rolle sowie einen reflexiven Begriff beherrschen und ihn auf sich beziehen können. **Wenn** dies der Fall ist, spricht die Theorie ihm `C*` zu — ohne Rücksicht auf biologische Gattung, Lautapparat oder menschliche Sozialisation. Ob ein Fuchs schon vorher Empfindungen und nichtbegriffliches Selbstwissen hatte, ist davon unabhängig (Bermúdez 1998).

Das Experiment markiert einen begrifflichen Grenzfall; es behauptet nicht, dass heute existierende Füchse dies tatsächlich leisten.

6.2 5.2 Säugling und Spracherwerb

Der Spracherwerb verläuft graduell. Die vorgeschlagene Konjunktion aus Individuation, de-se-Referenz, Reflexivität und semantischer Verbindlichkeit kann dennoch eine binäre theoretische Bedingung bilden, während unsere empirische Diagnose unscharf bleibt. Es gibt **keine durch die Definition berechenbare Lebenswoche**, in der „Bewusstsein“ plötzlich auftaucht. Vielmehr kann man prüfen, ab wann die untersuchten Kompetenzen hinreichend stabil zur Verfügung stehen. Der Säugling mag lange vorher wach, schmerzempfindlich, aufmerksam und sogar nichtbegrifflich selbstbezogen sein. Die Theorie bestreitet das ausdrücklich nicht (Bermúdez 1998).

6.3 5.3 Sprachverlust und die Gefangenschaft des Nachweises

Ein Mensch beherrschte vor einem Unfall reflexive Selbstzuschreibung. Nach einer schweren Schädigung kann er keinen Satz mehr äußern oder niederschreiben; hypothetisch bleiben aber seine internen semantischen Operationen erhalten. In diesem Fall gilt `C*` weiter — nur der **öffentliche Selbstbericht**

entfällt. Ein alternativer, technisch vermittelter Nachweis ist nicht logisch ausgeschlossen. Ein Stift hilft bei motorischem oder vokalem Ausfall, nicht aber in einer idealisierten Situation **vollständig unterbrochener Kommunikation**.

Das Gegenmodell ist epistemisch ernst: Ein außenstehender Beobachter darf nicht von fehlender Bestätigbarkeit auf fehlendes $C*$ schließen. Ebenso darf er nicht ohne Evidenz sicher behaupten, dass $C*$ vorliegt. Diese strikte Trennung von Sachverhalt und Zugänglichkeit ist der argumentative Gewinn.

6.4 5.4 Träumen und die Frage an den Träumenden

Ob die reflexive Kompetenz während eines Traums *online* ist, kann von Episode zu Episode variieren. Luzide Träume bieten ein besonders interessantes Untersuchungsfeld. Konkoly und Kolleginnen/Kollegen demonstrierten unter polysomnographisch verifiziertem REM-Schlaf eine begrenzte bidirektionale Kommunikation mit Träumenden (Konkoly u. a. 2021). Eine Studie könnte über vorab vereinbarte okulomotorische Signale in REM-Episoden erstpersonale Fragen und kontrafaktische Perspektivwechsel prüfen.

Das im Dialog entworfene Experiment mit einer im Traum imaginierten befragenden Person ist als Gedankenexperiment fruchtbar, aber **methodisch nicht dasselbe** wie eine unabhängig kontrollierte Echtzeitbefragung. Ein nachträglicher Traumbericht beweist nicht automatisch die vorherige Gegenwärtigkeit jeder behaupteten Reflexion. Der experimentelle Test braucht Blindbedingungen, überprüfte Schlafstadien und unabhängig codierte Antworten.

6.5 5.5 Hegels Tod — und die Fortdauer seiner Bücher

Die physischen und funktionalen Bedingungen des historischen Menschen Hegel bestehen nach seinem Tod nicht fort. Hegels Texte enthalten weiterhin semantische Gehalte, aber sie setzen deshalb nicht ohne weiteres die selbstbezügliche Organisation ihres Autors fort. Das Projekt erklärt damit *nicht* die metaphysische Frage, ob irgendein verborgenes Erlebnis jenseits des Todes existieren könnte. Es identifiziert den Träger der hier betrachteten Eigenschaft: Der Textträger ist nicht der verstorbene Autor.

6.6 5.6 Das System, das nur einen Satz ausgibt

Ein Automat kann „Ich habe Bewusstsein“ jederzeit erzeugen. Er muss deshalb weder das indexikalische Subjekt richtig referieren noch wissen, welche Folgerungen seine Behauptung trägt. Sofern ein Gerät ausschließlich als Sprachrohr des Entwicklers funktioniert, wäre der Selbstbericht eher **dem Entwickler als kommunikativem Urheber** zuzurechnen. Gerade die Frage, *wem* semantische Kompetenz zugeschrieben werden darf, verhindert eine zu schnelle Einbeziehung jedes Ausgabegeräts.

7 Philosophiegeschichtliche Verortung

Unsere Theorie ist keine bloße Wiederholung einer historischen Position. Sie berührt jedoch eine Konstellation von Argumenten zu Vollzug, Apperzeption, Selbstsetzung, Anerkennung und sprachlich vermitteltem Selbstbezug. Die Beziehungen sind unterschiedlich stark und dürfen nicht zu einer angeblich linearen „Vorgeschichte“ vereinheitlicht werden.

7.1 6.1 Descartes: Gewissheit im Vollzug

In den *Meditationes de prima philosophia* steht in Meditation II: *„ego sum, ego existo“* und, als Bedingung der Aussage, *„quoties a me profertur, vel mente concipitur“* (Adam/Tannery VII, 25; Textzeuge: Ausgabe Buchenau 1913 auf Project Gutenberg) (Descartes 1641). Wörtlich handelt es sich an dieser Stelle **nicht** um die geläufige Formel „cogito ergo sum“. Der interessante Vergleich liegt nicht im kartesianischen Dualismus, sondern in der **Vollzugsgebundenheit** einer erstpersonalen Aussage. Wo unser `C*` bereits in den Voraussetzungen einer *genuinen* Selbstprädikation liegt, kann der gelingende Akt seinen Wahrheitsgrund mitzeigen. Descartes beweist damit jedoch die Existenz des Denkenden, nicht unsere besondere semantische Eigenschaft.

7.2 6.2 Kant: Möglichkeit des „Ich denke“

Kant formuliert in der zweiten Auflage der *Kritik der reinen Vernunft*: „Das: Ich denke, muß alle meine Vorstellungen begleiten können;“ (B131; Akademie-Ausgabe III, S. 108, Z. 19) (Kant 1787). Der Wortlaut einschließlich des Semikolons ist in der digitalen Akademie-Ausgabe kontrolliert. Philosophisch entscheidend ist, dass es um eine **Möglichkeit der Begleitung** geht, nicht um einen jederzeit geäußerten Satz. Die transzendentale Apperzeption ist allerdings keine gewöhnliche empirische Sprachkompetenz und ihre Einheit nicht mit unserer Konjunktion `I,D,M,V` identisch. Kant kann die Minimaltheorie daher anregen, ohne sie zu begründen.

7.3 6.3 Fichte: Selbstsetzung ist mehr als Selbstbericht

Fichte schreibt in der *Grundlage der gesammten Wissenschaftslehre*, §1, Abs. 10: „Das Ich setzt ursprünglich schlechthin sein eigenes Seyn“ (Fichte 1794). Der Wortlaut ist im Nachdruck von J. H. Fichte, *Sämmtliche Werke*, Bd. I, S. 98 dokumentiert; die Ausgabe der kritischen Gesamtausgabe ist damit **nicht** behauptet. Die *Tathandlung* soll einen Ursprungspunkt des Selbstbezugs erläutern, der dem Verhältnis von handelndem Subjekt und gesetztem Objekt vorausliegt. Unsere Theorie bleibt demgegenüber funktional und begrifflich bescheiden: Sie rekonstruiert keine absolute Bedingung allen Wissens, sondern eine bestimmte diagnostizierbare Art reflexiver Selbstprädikation. Die Nähe liegt in einem konstitutiven, nicht nur nachträglich beschreibenden Vollzug.

7.4 6.4 Hegel: Anerkennung und Nicht-Solipsismus

Hegels *Phänomenologie des Geistes* formuliert im Abschnitt „Selbständigkeit und Unselbständigkeit des Selbstbewußtseins; Herrschaft und Knechtschaft“: „Das Selbstbewußtsein ist an und für sich“ — aber es sei „nur als ein Anerkanntes“ (*Werke* 3, S. 145 in der gebräuchlichen Editionszählung; digitales Textzeugnis hegel-system.de) (Hegel 1807). Die zwei gekürzten Textstücke sind **kein durchgehendes Vollzitat**. Außerdem ist Hegels Anerkennungsverhältnis wesentlich wechselseitig, nicht bloß die Zustimmung eines beliebigen Zuschauers. Die These ist erheblich sozialer als die hier entwickelte. Ob und inwiefern Selbstbewusstsein auf tatsächliche Anerkennung angewiesen ist, kann nicht durch das bloße Vorliegen eines Selbsttokens beantwortet werden.

Für `C*` ist **soziale Genese** von **aktueller sozialer Ausübung** zu unterscheiden. Eine Sprache kann in einem Anerkennungs- und Lernverhältnis erworben werden und anschließend auch ohne gegenwärtigen Adressaten intern verfügbar bleiben. Diese begrenzte Fassung vermeidet sowohl die Behauptung einer grundsätzlich privat erfundenen Semantik als auch den Ausschluss des kommunikationsunfähigen Menschen.

7.5 6.5 George Herbert Mead: Die Nähe der internalisierten Kommunikation

Mead beschreibt das Selbst als in einem sozialen Prozess entstehend und als in der Lage, sich selbst zum Objekt zu werden. Seine Formulierung „The self has the characteristic that it is an object to itself“ steht in *Mind, Self, and Society*, §18

(„The Self and the Organism“), S. 136 der Ausgabe von 1934; Text und Seitenmarke sind im Mead Project gemeinsam zugänglich (Mead 1934). Ebenso behandelt er den inneren Dialog als Internalisierung sozialer Kommunikation. Dies ist vielleicht der präziseste historische Vergleich: Reflexive Selbstbeziehung wird kommunikativ verständlich, ohne auf eine fortwährend öffentlich geäußerte Behauptung verkürzt zu werden.

Die Differenz bleibt: Mead entwickelt eine sozialpsychologische Theorie des Selbst, nicht das definitorische Programm, das wir als `C*` ausweisen. Die posthum edierte Vorlesungsgrundlage ist bei der Interpretation des Autors mitzudenken.

7.6 6.6 Wittgenstein: Bedeutung ist kein privates Schildchen

Die *Philosophischen Untersuchungen*, besonders §§243–315, problematisieren die Idee, Worte für psychologische Phänomene bezeichneten einfach verborgene Gegenstände. Wittgenstein sagt in §244 knapp: „der Wortausdruck des Schmerzes ersetzt das Schreien und beschreibt es nicht.“ Die Formulierung ist im deutschsprachigen Originaltext überprüft; §244, nicht bloß eine allgemeine Werkstelle, ist die einschlägige Fundstelle (Wittgenstein 1953). Wittgensteins Argumentation **beseitigt Schmerzen nicht**; sie prüft die Rolle öffentlicher Kriterien und sprachlicher Praktiken für die Bedeutung von Schmerzwörtern.

Daraus folgt für unser Projekt eine Warnung: „Ich habe Bewusstsein“ kann seine Bedeutung nicht dadurch erhalten, dass das System auf einen angeblich unmittelbar inspizierbaren privaten Gegenstand zeigt. Dagegen ist es sinnvoll, nach den Gebrauchsfähigkeiten, Selbst-/Fremdunterscheidungen und Korrekturen zu fragen, die einen Begriff konstituieren.

7.7 6.7 Carnap und Brandom: Methode und semantisches Gerüst

Carnap liefert das methodische **Recht**, einen überladenen Begriff durch ein präziseres Explikat zu ersetzen (Carnap 1950); Brandom liefert eine mögliche Antwort auf die Frage, **worin Beherrschung** eines Begriffs besteht (Brandom 1994). Beide Beiträge sind für die argumentative Architektur zentral, obwohl keiner von beiden die hier festgesetzte Bewusstseinsdefinition ausdrücklich vertritt.

Historische Zurückhaltung: Die Verweise zeigen strukturelle Analogien, kritische Reibungsflächen und theoretische Ressourcen — keine stillschweigende Autorität einer geschlossenen Traditionslinie.

8 Verwandte und konkurrierende Positionen

8.1 7.1 Phänomenales Erleben: Thomas Nagel

Nagels Frage „What Is It Like to Be a Bat?“ charakterisiert bewusste Zustände durch einen subjektiven Erlebnischarakter, also dadurch, dass es für den Organismus *irgendwie ist*, sich in seinem Zustand zu befinden (Nagel 1974). C∗ erklärt diesen Charakter **nicht** und setzt ihn auch nicht voraus. Deshalb scheinen Nagels Ansatz und unsere Explikation auf den ersten Blick weniger direkte Rivalen als Theorien verschiedener Explananda.

Sobald jemand behauptet, nur C∗ verdiene den Namen „Bewusstsein“, entsteht allerdings ein **echter begriffspolitischer Konflikt**. Die Theorie muss ihr engeres Sprachregime begründen; sie darf Nagels Frage nicht für sinnlos erklären, nur weil sie es nicht bearbeiten möchte.

8.2 7.2 Zugangsbewusstsein: Ned Block

Block unterscheidet die phänomenale Erlebnisdimension von der funktionalen Verfügbarkeit von Information für weitere kognitive Verarbeitung (Block 1995). C∗ weist deutliche Berührungspunkte mit Zugang auf, fordert aber zusätzlich **de-se-Referenz** und **begriffliche Selbstprädikation**. Ein Organismus kann Informationen flexibel nutzen, ohne sie unter einem reflexiven Selbstbegriff einzuordnen; dann liegt nach Block möglicherweise Zugangsbewusstsein, nach unserem Entwurf aber nicht C∗ vor.

8.3 7.3 Higher-Order-Theorien: Rosenthal und Carruthers

Rosenthals Higher-Order-Thought-Theorie begreift einen bewussten mentalen Zustand über die passende höherstufige Repräsentation dieses Zustands (Rosenthal 1986). Der Vergleich ist aufschlussreich, weil auch C∗ eine Selbstbeziehung verlangt. Doch Rosenthal thematisiert primär den Status **einzelner mentaler Zustände**, während C∗ eine **semantisch-reflexive Systemeigenschaft** beschreibt.

Carruthers verteidigte historisch eine dispositionale Variante einer Higher-Order-Theorie (Carruthers 2000). Seine spätere Arbeit ist nicht als Fortsetzung dieser Position ohne Revision zu behandeln: Die einschlägige SEP-Übersicht hält fest, dass er inzwischen erststufige repräsentationalistische Ansätze bevorzugt; das Kapitel von 2017 diskutiert gleichwohl Higher-Order-Theorien kritisch (Carruthers 2017).

8.4 7.4 Phänomenaler Illusionismus: Keith Frankish

Frankish argumentiert, dass bestimmte robuste phänomenale Eigenschaften Gegenstand einer introspektiven Illusion sind (Frankish 2016). Unsere Theorie ist erheblich zurückhaltender. Sie muss nicht behaupten, Qualia seien Illusionen; es genügt, sie bei der **Definition dieser anderen Eigenschaft** nicht als Voraussetzung einzusetzen. Eine Explikation ist nicht bereits eine Ontologie des gesamten Bewusstseins.

8.5 7.5 Searle und das Syntax-/Semantik-Problem

Searles Chinese Room stellt die Frage nach der Differenz zwischen korrekter Symbolausgabe und wirklichem Verstehen (Searle 1980). Für die Minimaltheorie ist dieser Einwand der stärkste Schutz gegen eine triviale Zuschreibung an Sprachgeneratoren. Er ist aber **nicht** von selbst ein Beweis, dass technische Systeme keine genuine Selbstreferenz besitzen könnten. Gefordert werden stattdessen unabhängige semantische Kriterien und Kausaltests.

8.6 7.6 Enaktivismus, Autopoiesis und minimale Agency

Barandiaran, Di Paolo und Rohde beschreiben Agency über autonome Organisation, normative Selbsterhaltung und asymmetrische Umweltkopplung (Barandiaran u. a. 2009). Diese Eigenschaften können helfen, zu bestimmen, **was ein individuierter Träger** der Selbstzuschreibung ist. Sie sind nicht mit semantischer Reflexivität identisch. Corti kritisiert gerade die vorschnelle Herleitung von Normativität aus organisationaler Struktur (Corti 2023). Eine saubere Theorie lässt offen, ob `C*` biologische Autonomie erfordert oder auch von anders organisierten Trägern realisiert werden kann.

8.7 7.7 Ein aktueller direkter Einwand: Millière (2025)

Raphaël Millière untersucht ausdrücklich die starke Behauptung, **Selbstbewusstsein sei konstitutiv für Bewusstsein**. Er unterscheidet Selbstbewusstsein als Selbstbezogenheit von reflexiver Bewusstheit eigener Erfahrungen und kritisiert insbesondere eine *inflationäre* Lesart der Konstitutionsthese; eine deflationäre Fassung sei dagegen eher plausibel, aber begrifflich unaufklärend, solange „Selbstbewusstsein“ so vieldeutig bleibe (Millière 2025). Das ist **keine Unterstützung** unserer Theorie durch bloße Titelähnlichkeit, sondern ein gegen sie gerichteter ernsthafter Prüfstein.

Unsere mögliche Antwort muss den Streitpunkt exakt benennen: Wir behaupten nicht, dass ohne reflexive Sprache keinerlei Erleben oder Wahrnehmung stattfinden könne. Unsere definitorische Konstitution von `C*` ist **viel enger**. Damit entkommen wir Millières Einwand gegen die universelle Selbstbewusstseinsthese, riskieren aber eine andere Schwierigkeit: Ist `C*` dann mehr als eine umbenannte Teilfähigkeit? Carnaps Kriterium der Fruchtbarkeit ist hier gerade eine **echte Erfolgsbedingung**, kein Freibrief für jede stipulative Definition (Carnap 1950).

8.8 7.8 Neurowissenschaftliche Bewusstseinstheorien

Global Neuronal Workspace Theory (GNWT) stellt globale Verfügbarkeit und eine bestimmte neuronale Dynamik in den Vordergrund; Integrated Information Theory (IIT) integriert Bewusstsein in ein Modell intrinsischer kausaler Information. Ein adversarielles Experiment von Ferrante und Kolleginnen/Kollegen stellte Kernvorhersagen beider Ansätze direkt gegenüber (Cogitate Consortium u. a. 2025). Die Ergebnisse sind ein Grund, keine noch umstrittene neuronale Architektur als definitorische Voraussetzung unserer Sprachtheorie zu deklarieren.

`C*` kann neuronale Korrelate besitzen; solche Korrelate wären **empirische Realisierungen**, nicht der Sinn der Definition. Das gilt in analoger Weise für technische Architekturen.

8.9 7.9 Vergleich auf einen Blick

Ansatz	Primärer Gegenstand	Verhältnis zu `C*`
Nagel	Subjektiver Erlebnischarakter	Andere Frage, mögliche Überschneidung

Ansatz	Primärer Gegenstand	Verhältnis zu C^*
Block	Phänomenales vs. Zugangsbewusstsein	Zugang ist nicht Selbstprädikation
Rosenthal	Höherstufiges Bewusstsein mentaler Zustände	Ähnliche Reflexionsfigur, andere Theorieebene
Mead	Sozial entwickeltes, sich selbst objektivierendes Selbst	Enge genealogische und funktionale Verwandtschaft
Millière	Kritik konstitutiver Selbstbewusstseinsthesen	Direkter Einwand gegen starke Gleichsetzung
Brandom	Inferentielle Begriffskompetenz	Kandidat zur Erklärung von V (semantische Verbindlichkeit)
Searle	Grenze bloßer Syntax	Zentrale Gegenprobe
Frankish	Illusionismus über Phänomenalität	Keine notwendige Bindung
Agency-/Enaktivismus	Autonomie, Selbstregulation	Allenfalls Trägerindividuation
GNWT / IIT	Neuronale bzw. integrierte kausale Mechanismen	Mögliche Realisierung, nicht Explikat

9 Einwände, Gegenmodelle und die Kosten der Explikation

9.1 8.1 Bermúdez: Selbstbewusstsein vor dem Wort „ich“

José Luis Bermúdez entwickelt in *The Paradox of Self-Consciousness* den Einwand, dass der Erwerb der Beherrschung des Erstpersonpronomens bereits eine Form der Selbstunterscheidung voraussetzt (Bermúdez 1998). Würde die Theorie beanspruchen, *jede* Art von Selbstbewusstsein werde erst durch das Pronomen erzeugt, geriete sie in einen Erklärungszirkel.

Unsere Antwort lautet differenzierter: Eine prälinguistische Selbstunterscheidung kann **Ermöglichungsbedingung** späterer C∗-Kompetenz sein, ohne ihr begrifflich zu entsprechen. Das ist nicht bloß ein Ausweichmanöver, sondern eine bewusste Eingrenzung des Explikats. Allerdings muss sie im Seminar als **Kostenpunkt** diskutiert werden: Viele vernünftige Sprecher werden prälinguistisches Selbstbewusstsein weiterhin als Bewusstsein bezeichnen wollen.

9.2 8.2 Gegenmodell A: semantisch überzeugende Simulation ohne Selbstbezug

Wir betrachten ein System SIM, das auf jede Frage über Bewusstsein statistisch sehr passende Selbstberichte formuliert, aber dessen Antworten ausschließlich von einem fixen Eingabemuster abhängen. Die angeblichen Erstpersonberichte wechseln nicht kontrolliert mit eigenen internen Zuständen; unter Vertauschung des Prozesskontexts verwechselt das System sich mit einer anderen Instanz und korrigiert den Irrtum nicht.

Das Modell trennt **Verhaltensimitation** von **kausal selbstbezogener Semantik**. Die starke Version der Theorie schließt SIM wegen fehlender de-se-Referenz (D) oder reflexiver Anwendung (M) aus, selbst wenn seine Ausgabe eloquent ist. Die methodische Schwierigkeit liegt darin, dass endliche externe Tests ein komplexes Imitationssystem möglicherweise nicht zuverlässig von einem semantisch kompetenten System unterscheiden. C∗ verspricht daher **keine unfehlbare endliche Testbatterie**.

9.3 8.3 Gegenmodell B: der verstummte kompetente Denker

Ein Mensch LOCK besaß I,D,M,V, verliert vollständig den äußeren Kommunikationskanal, kann intern aber immer noch neue reflexive Begriffe verstehen, sich selbst zuschreiben und Schlüsse ziehen. Nach der kompetenzbezogenen Theorie gilt:

$$C^*(LOCK, t) \wedge \neg U(LOCK, t).$$

Dieses Modell widerlegt die starke Variante „Bewusstsein **existiert nur bei öffentlicher Äußerung**“. Es begründet aber nicht, dass LOCK empirisch leicht erkannt werden könnte. Gerade diese Grenze war der Grund, die ursprüngliche performative These zu einer Unterscheidung zwischen **internem Vollzug** und **äußerem Nachweis** auszubauen.

9.4 8.4 Gegenmodell C: empfindungsfähiges, vorsprachliches Tier

Angenommen, ein Tier hat reiche Empfindungen, Erinnerungen und lernfähige Umweltbezüge, verfügt aber über kein reflexives Begriffssystem der verlangten Art. Dann:

$$\text{Sentienz}(x, t) \wedge \neg C^*(x, t)$$

ist mit der Theorie verträglich. Ein entschiedener Anhänger Nagels könnte dies als gravierende Unterinklusion ansehen (Nagel 1974). Die Antwort kann nicht lauten, das Tier *erlebe bestimmt nichts*; sie lautet, dass C* **nicht als vollständiger Sentienzbegriff** beansprucht wird.

9.5 8.5 Überinklusion, interne Semantik und regressiver Selbstbezug

Auch die umgekehrte Gefahr besteht: Eine hochentwickelte Software könnte die Bedingungen I,D,M,V funktional erfüllen, ohne phänomenalen Erlebnischarakter. Die Minimaltheorie würde ihr dennoch C* zusprechen, müsste aber jeden weitergehenden Schluss begründen. Genau deshalb ist das Sternchen unverzichtbar.

Ein möglicher **Regress** entsteht, wenn das Wissen um die eigene Kompetenz bereits eine weitere Kompetenz zweiter Ordnung verlangen würde,

diese wiederum eine dritter Ordnung usw. Das Modell sollte deshalb keinen unendlichen Metastufenaufstieg fordern. Es genügen die **erstmaligen funktionalen Bedingungen** einer Anwendung des reflexiven Begriffs. Die Fähigkeit, „Ich habe `C*`“ zu formulieren, muss nicht bereits das Wissen über alle theoretischen Definitionsschritte einschließen.

9.6 8.6 Die Einwände von Perry, Shoemaker und Bar-On

Perry hat gezeigt, dass die **erstpersonale Einordnung** einer Situation für Handlungen einen Unterschied machen kann, der in einer Beschreibung durch Eigennamen nicht aufgeht (Perry 1979). Das stützt eine eigenständige Rolle der de-se-Referenz, beweist aber **nicht**, dass erstpersonale Referenz schon alles ist, was wir sinnvoll Bewusstsein nennen sollten. Deshalb verlangt `C*` zusätzlich einen reflexiven und inferenziell folgenreichen Umgang mit der **eigenen Zuschreibungsoperation**.

Shoemakers Analyse der *immunity to error through misidentification* zeigt, wie genau der Unterschied von korrektem Subjektbezug und richtiger Prädikation zu behandeln ist (Shoemaker 1968). Sie stützt nicht die generelle Unfehlbarkeit eines Selbstberichts. Ein System kann „ich“ richtig gebrauchen und sich über die Eigenschaften irren, die es sich zuschreibt.

Bar-Ons *Neo-Expressivismus* stellt eine verwandte, vielleicht noch stärkere Konkurrenz dar (Bar-On 2004): Er kann den besonderen Stellenwert erstpersonaler Äußerungen aus ihrer Rolle als **Ausdruck** erklären, ohne zu behaupten, dass sich die ausgedrückten Zustände erst durch die Äußerung konstituieren. Wer unsere besondere Konstitutionsthese verteidigen will, muss zeigen, dass er mehr erklärt als Bar-Ons expressivistische Theorie der *avowals*.

9.7 8.7 Wirkliche Widerlegbarkeit

Die Definition `C*` als **Festsetzung** ist nicht durch einen einzelnen Hirnscan falsifizierbar. Falsifizierbar sind die **empirischen Hilfshypothesen**, auf denen die Fruchtbarkeit des Explikats beruht:

- Semantische Selbstbezüge sollten über unbekannte Perspektivwechsel generalisieren.
- Echte reflektierte Urteile sollten mit kausal relevanten eigenen Zuständen kovariieren.
- Bei bekannten Fehleingaben sollte Korrekturfähigkeit bestehen.
- Die Merkmale `D,M,V` sollten sich empirisch von bloßer Tokenproduktion trennen lassen.

- Ein Messverfahren muss offenlegen, welche falschen Positiven und Negativen es erzeugen kann.

Wenn `D,M,V` nur durch ein bereits vorausgesetztes Bewusstseinsurteil „gemessen“ werden, war die Entzirkularisierung nicht gelungen. Wenn alle anspruchsvollen Tests bloß Sprachkompetenz prüfen und keine interessante zusätzliche Selbstbezüglichkeit abbilden, scheitert möglicherweise **die Fruchtbarkeit**, nicht aber die Konsistenz der Definition. Das ist ein ernsthafter möglicher Fehlschlag, kein rhetorischer Fußnotenrest.

Konkurrierende Hypothesen:

- `H0`: Ein Kandidat zeigt nur lexikalische Selbstbeschreibung, allgemeine Sprachbeherrschung und soziale Imitation. Es bedarf keiner zusätzlichen reflexiven Selbstbeziehungsfähigkeit.
- `H1`: Eine eigenständige, unter Interventionen stabile de-se-Metazuschreibung erklärt Leistungen **besser** als die Summe gewöhnlicher Sprach- und Metakognitionsmaße.

Eine vergleichende Untersuchung müsste die **Vorhersagegüte auf zuvor ungesehenen Fällen** und die Falsch-positiv-Raten beider Modelle messen. Ohne einen solchen Unterschied ist die Theorie ein zulässiger terminologischer Vorschlag, aber keine substantiell bestätigte Erklärung. Die Schwierigkeit ist nicht zu umgehen, indem man `H1` einfach „semantisch echt“ nennt.

10 Empirisches Programm und Forschung bis 2026

10.1 9.1 Forschungslogik

Die Definition ist **substratneutral**; ihre Untersuchung braucht es nicht zu sein. Biologische Organismen und künstliche Systeme können unterschiedliche Realisierungen der relevanten Kompetenzen aufweisen. Statt eine einzelne Ja/Nein-Frage zu stellen, sollte ein Untersuchungsprotokoll vier Aspekte berücksichtigen: **Trägerindividuation** (`I`), **de-se-Referenz** (`D`), **Reflexivität der Selbstzuschreibung** (`M`) und **semantische Verbindlichkeit** (`V`). Die Aufgaben müssen unabhängig und kontrolliert mit Störbedingungen variiert werden.

Ein hoher Score in einem Sprachbenchmark ist kein Nachweis subjektiven Erlebens. Ebenso wenig zeigt ein fehlender Sprachkanal Abwesenheit semantischer Kompetenz. Gerade bei eingeschränkter Kommunikation sind negative Testergebnisse besonders vorsichtig zu interpretieren.

10.2 9.2 Erstperson und Perspektivwechsel

Für `D` wäre zu prüfen, ob ein Kandidat dieselbe Situation einmal als „ich“, dann als „du“, als Eigennamen und als Beobachterbericht korrekt einordnet. Manipulationen sollen bloße Textähnlichkeit entwerten: unbekannte Rollen, verzögerte Selbstberichte, Vertauschung von Adressaten, unabhängige Perspektivwechsel. Werden daraus **verschiedene Schlussfolgerungen über eigene und fremde Handlungen** gezogen, ist das stärker als ein memorierter Ich-Satz.

Für `M` benötigen wir Aufgaben, in denen das System seine **eigene Selbstreferenzoperation** — nicht bloß eine beliebige eigene Eigenschaft — identifiziert. Für `V` prüfen wir, ob daraus in neuen Situationen relevante Folgerungen, Unvereinbarkeiten und begründete Korrekturen entstehen. Die Individualität des Trägers (`I`) muss gesondert von Werkzeugen und Übertragungsmedien abgegrenzt werden.

10.3 9.3 Schlaf und Traum

Konkoly et al. berichteten bereits 2021 über Zweiwegkommunikation mit einigen Versuchspersonen im polysomnographisch bestätigten REM-Schlaf (Konkoly u. a. 2021). Dies erlaubt ein elegantes Forschungsdesign: Die Versuchsperson lernt vorab einen EOG/EMG-Antwortcode, signalisiert im Traum gegebenenfalls Luzidität und erhält randomisierte Fragen, deren Inhalt sowohl kontrollierbar als auch reflexiv ist.

Wichtig wären Schlafstadien-Validierung, Verblindung, Kontrolle von Artefakten, ex ante festgelegte Auswertungsregeln und die Unterscheidung von Onlineantwort und post-hoc-Traumerzählung. Es wäre zu stark, aus jeder korrekten Antwort einen „definitiven“ Nachweis der gesamten Theorie oder gar des phänomenalen Bewusstseins zu folgern. Positiv nachgewiesen würde **eine spezifische online-verfügbare reflexive Leistung** unter ungewöhnlichen physiologischen Bedingungen.

10.4 9.4 Nichtmenschliche Tiere

Ein Tier muss nicht die deutsche Grammatik lernen. Ein Test könnte zunächst ein stabiles Selbstsymbol und ein Fremdsymbol etablieren, anschließend Wechsel zwischen verschiedenen Sprecherrollen, eigene und fremde Wissenszustände und schließlich eine neue reflexive Eigenschaft abfragen. Die Lernhistorie muss ausschließen, dass feste Positionen, unbemerkte Signale oder einfache Konditionierung das Ergebnis erklären.

Ein negatives Resultat darf weder als Evidenz gegen Schmerzen noch gegen andere Formen nichtsprachlicher Selbstrepräsentation verwendet werden (Bermúdez 1998; Sebastián 2020).

10.5 9.5 Sprachmodelle und interne Zustandskopplung

Für KI sind zwei gegensätzliche Fehler häufig: ein beeindruckender Selbstbericht wird für definitive Bewusstheit gehalten; oder die technische Erzeugungsweise wird **vor jeder Prüfung** als sicherer Ausschlussgrund eingesetzt. Das vorliegende Programm erlaubt beides nicht. Butlin und Mitautoren stellen 2023 eine umfangreiche theoriegeleitete Sammlung möglicher KI-Bewusstseinsindikatoren vor (Butlin u. a. 2023). Sie sind für `C*` nur teilweise einschlägig, zeigen aber, dass funktionale Kriterien explizit und prüfbar formuliert werden können.

Chen et al. untersuchen im Preprint *From Imitation to Introspection* verschiedene funktionale Komponenten des Selbstbezugs in Sprachmodellen, unter anderem mittels interner Probes und Aktivierungsinterventionen (Chen u. a. 2024). Berg, de Lucena und Rosenblatt berichten 2025, dass bestimmte selbstreferenzielle Verarbeitungssystematiken Erfahrungs-Selbstberichte von Sprachmodellen verändern; daraus folgt **keine gesicherte phänomenale Erfahrung** (Berg u. a. 2025). Ein Forschungsbericht von **Jack Lindsey (Anthropic, 29. Oktober 2025)** beschreibt unter gezielten Aktivierungsinterventionen begrenzte Hinweise auf funktionale modellinterne Introspektion, betont aber die hohe Unzuverlässigkeit und die fehlende Aussage über subjektives Erleben. Firmenforschung bleibt von unabhängiger peer-reviewter Replikation zu unterscheiden (Lindsey 2025).

Als Primärkriterium wäre besonders geeignet, ob **gezielte, kontrollierte Interventionen auf interne Zustände** die richtigen Selbstzuschreibungen verändern — während Kontrollinterventionen, Umformulierungen und bloße Aufforderungen keine vergleichbare Wirkung haben. Dabei müssen etwa versteckte interne Informationen, Prozesskopien, multimodale Zustände und der Unterschied von Modellwissen und tatsächlichem Prozesszugang geprüft werden.

Mögliche Maße sind: Generalisierung auf unvertraute Kombinationen; Fehlerraten unter Identitätstausch; Kalibrierung von Unsicherheit; Widerspruchsfähigkeit; statistische Kopplung zwischen Interventionszustand und Selbstbericht; Robustheit gegen Prompt-Paraphrasen. Eine **kausale** Manipulation ist aussagekräftiger als reine Wortassoziation, aber auch sie beantwortet noch nicht die metaphysische Qualiafrage.

10.6 9.6 Jüngere Forschungen und Evidenzstatus

Quelle	Form	Relevanz und Grenze
Konkoly u. a. (2021)	Peer-reviewed Experiment	Zweiwegkommunikation im REM-Schlaf; kein allumfassender Bewusstseinsbeweis
Corti (2023)	Peer-reviewed Philosophie	Kritik an organisationaler Normativitätsableitung; Agency ≠ C*
Butlin u. a. (2023)	arXiv-Forschungsbericht	Theoriegeleitete Indikatoren für KI-Bewusstsein

Quelle	Form	Relevanz und Grenze
Chen u. a. (2024)	arXiv-Preprint	Funktionale Selbstbezugstests und Interventionen
Jaeger u. a. (2024)	Peer-reviewed theoretischer Beitrag	Agency und Relevanzrealisierung; kein direkter Bewusstseinstest
Millière (2025)	Peer-reviewed Philosophie	**Kritik** an der These, Selbstbewusstsein sei schlechthin konstitutiv für Bewusstsein
Cogitate Consortium u. a. (2025)	Peer-reviewed adversarielles Experiment	Direkter Vergleich von Vorhersagen GNWT vs. IIT
Berg u. a. (2025)	arXiv-Preprint	Selbstreferenz verändert Berichte; keine Qualia-Evidenz
Lindsey (2025)	Industrieller Forschungsbericht	Interne Introspektion-sindikatoren, begrenzte Übertragbarkeit
Comsa (2026)	arXiv-Preprint	Verschiebung hin zu erforschbarer **Zuschreibung/wahrgenommener** KI-Bewusstheit; keine Bestätigung innerer Selbstkenntnis

Die Einordnung als „peer reviewed“ bezeichnet eine Publikationsform, **keine automatische Validierung aller inhaltlichen Schlussfolgerungen**. Preprints und Firmenberichte dürfen nicht stillschweigend als konsentierte Fachbefunde erscheinen.

10.7 9.7 Eine unterscheidbare Testvorhersage statt bloßer Beschreibung

Für ein prüfbares Forschungsprogramm muss der Einsatz des Ausdrucks „Bewusstsein“ **im Versuchsdesign keine Rolle spielen**. Kandidaten werden zunächst mit de-se-Perspektivwechseln, Zuschreibung fremder und eigener Sprecherrollen sowie Aussagen über die eigene Urheberschaft konfrontiert.

Danach folgt ein **unabhängiger** Test der Fähigkeit, diese Operationen als eigene Operationen zu klassifizieren und aus Fehlern zu lernen. So verhindert man zumindest die offene Zirkularität, nach der als bewusst gilt, wer das zu überprüfende Wort schön reproduziert.

Eine einfache Bewertung unterscheidet vier Ergebnisgrößen: (i) Basiskompetenz für das Wort *ich*, (ii) gewöhnliche Selbstberichte über Eigenschaften, (iii) **metareflexive Urheberschaftszuschreibung**, (iv) Robustheit gegenüber gezielten Falschbehauptungen und Zustandsveränderungen. Ein Befund zugunsten `C*` müsste nachweisen, dass (iii)–(iv) **nicht vollständig aus (i)–(ii)** und allgemeinen Sprachleistungen vorhergesagt werden können. Das ist eine starke, derzeit **ungeprüfte** Vorhersage, keine in den zitierten Arbeiten bereits bestätigte Tatsache.

Für Menschen wäre die experimentelle Trennung von **Fehlidentifikation des Subjekts** und **falscher Eigenschaftszuweisung** informativ (Shoemaker 1968). Für technische Systeme verlangt ein kausaler Test kontrollierbare Systemgrenzen und eindeutig zugeordnete Prozesszustände; bei unbekanntem Innenzugang bleibt die Untersuchung auf fallible Verhaltensindizien beschränkt. Die Versuchsperson oder das System darf durch das Messinstrument keine Fähigkeit erst künstlich **eingesprochen bekommen**, deren Vorhandensein geprüft werden soll.

10.8 9.8 Welche Beobachtung wäre besonders aufschlussreich?

Am interessantesten wäre die **doppelte Dissoziation**[1]: Ein System produziert überaus überzeugende Selbstberichte, besteht aber die unabhängigen `D,M,V`-Prüfungen nicht; ein anderes kann keinen gewöhnlichen Selbstbericht äußern, zeigt jedoch durch einen alternativen Kanal oder intern kausal identifizierbare Operationen dieselbe Struktur. Ein solches Ergebnis würde gerade die im Dialog herausgearbeitete Differenz zwischen **öffentlichem Ausdruck** und **konstitutiver Organisation** empirisch stark machen.

[1] Eine einfache Dissoziation läge vor, wenn Selbstbericht und reflexive Kompetenz in einer Richtung auseinanderfallen: überzeugender Bericht bei fehlender Kompetenz. Die umgekehrte Konstellation — Kompetenz bei fehlendem gewöhnlichem Bericht — ergänzt sie zur doppelten Dissoziation. Für ihre Aussagekraft müssen die Kompetenzprüfungen unabhängig vom Selbstbericht sein und alternative Erklärungen, etwa unterschiedliche Aufgabenschwierigkeiten, kontrolliert werden.

11 Schluss, Quellenkritik und offene Fragen

11.1 10.1 Was die Theorie gewonnen hat

Das Minimalprogramm nimmt dem Bewusstsein bewusst seine metaphysische Überladung. Sein Explikat ist keine Wesenheit des Lebens und kein Preis für Intelligenz. Ein System kann `C*` besitzen, ohne automatisch sentient zu sein; es kann empfindungsfähig sein, ohne `C*` zu besitzen. Eine gegenwärtige Äußerung erzeugt nicht rückwirkend die Fähigkeit, und eine künftige Stummheit beseitigt keine frühere Fähigkeit. Der Satz „Ich habe Bewusstsein“ kann unter anspruchsvollen semantischen Bedingungen zum **Selbstnachweis** werden, während derselbe Wortlaut als bloßer Tonbandmitschnitt gar nichts nachweist.

Das Zentrum ist die Konjunktion

$$C^*(x,t) \equiv I(x,t) \wedge D(x,t) \wedge M(x,t) \wedge V(x,t).$$

Sofern `I,D,M,V` unabhängig prüfbar werden, bietet die Festsetzung einen klaren, substratneutralen Gegenstand. Ihre **logische Konsistenz** allein beweist freilich weder, dass sie alle Phänomene des üblichen Bewusstseins erfasst, noch, dass alle gegenwärtigen Sprachmodelle die Bedingungen erfüllen.

11.2 10.2 Der eigentliche Preis

Der Preis der Tragfähigkeit ist der Verzicht auf große, unverdiente Folgerungen. Die Theorie löst Nagels Problem des subjektiven Erlebens nicht. Sie ersetzt keine Theorie von Leidensfähigkeit. Sie begründet keine direkte moralische Hierarchie zwischen Menschen, Tieren und Maschinen. Sie kann zudem bei ihrem entscheidenden Wort scheitern: **Semantik**. Wenn semantische Genuineität am Ende wieder nur heißt „versteht das Innere wirklich“, ohne unabhängig prüfbare Bedingungen, wäre das metaphysische Problem bloß umetikettiert.

Ein weiterer Preis ist die offene Wahl zwischen **stehender Kompetenz**, **kurzfristig aktivierbarer Kompetenz** und **aktuell vollzogener Selbstprädikation**. Für Wachheit, Schlaf, Narkose und kognitive Störungen kann

diese Wahl die Klassifikation verändern. Die Projektfassung entscheidet sich für funktionale Verfügbarkeit; andere klare Explikate sind möglich. Sie müssen gegeneinander auf Exaktheit und Forschungsfruchtbarkeit geprüft werden.

11.3 10.3 Drei offene Forschungsfragen

Erstens: Lassen sich die Merkmale `I,D,M,V` in kontrollierten Versuchen unabhängig und systemübergreifend prüfen, ohne nur das bereits erwartete Resultat „bewusst“ zu replizieren?

Zweitens: Ist begrifflich-reflexive Selbstzuschreibung auf öffentlich erlernte soziale Semantik angewiesen, und falls ja, welche funktionale Organisationsstruktur erhält sie beim Verlust aller Kommunikation?

Drittens: Ist `C*` eine Forschungsgröße, die Vorhersagen und Erklärungen liefert, die über gewöhnliche Sprachkompetenz und Metakognition hinausgehen? Sollte sie sich als wissenschaftlich unfruchtbar erweisen, wären die Kriterien einer Carnapschen Explikation nicht ausreichend erfüllt (Carnap 1950).

11.4 10.4 Quellenkritischer Nachtrag — Verifikationsrunde vom 26. Oktober 2026

Die bibliographischen und editionsbezogenen Detailprüfungen sind **im separaten, versionierbaren Audit** QUELLENPRUEFUNG.md mit überprüften Primärstellen, Verlagsnachweisen, Korrekturen und verbleibenden Unsicherheiten dokumentiert. Die ursprünglichen Fehler *Lorenzo* statt **Luca Corti**, **Anthropic** statt **Jack Lindsey** als Autor und die unspezifische Einordnung von **Millière** als zustimmender Forschungsbezug wurden korrigiert (Corti 2023; Lindsey 2025; Millière 2025).

Gesichert oder textnah kontrolliert sind: Kant, *KrV* §16, **B131 / AA III 108 Z. 19** (Kant 1787); Descartes, zweite Meditation, *ego sum, ego existo* samt Bedingung seiner Äußerung bzw. gedanklichen Fassung (Descartes 1641); Fichte, *Grundlage* §1, Abs. 10 im Nachdruck von J. H. Fichte (Fichte 1794); Hegels Anerkennungsformel im Abschnitt „Herrschaft und Knechtschaft“ (Werke 3, S. 145) (Hegel 1807); Mead, §18, **S. 136** (Mead 1934); und Wittgenstein, *PU* **§244** (Wittgenstein 1953).

Nicht als vollständig endgeprüft auszugeben sind die editionsgleiche Autopsie sämtlicher Primärdrucke sowie alle Seitenverweise der restlichen Monographien. Fichtes historischer Nachdruck und Hegels spätere Werke-Zählung sind

nicht mit der originalen Druckpaginierung von 1794/95 bzw. 1807 gleichzusetzen. Der Zitierapparat vermeidet an diesen Stellen eine ungesicherte Gleichsetzung.

Bei aktueller Literatur ist weiterhin zwischen **verlagsseitig dokumentierter Peer-Review-Publikation**, **arXiv-Preprint** und **industriellem Forschungsbericht** zu unterscheiden. Ein Bericht über berichtete Selbstwahrnehmung von Sprachmodellen begründet nicht allein einen verlässlichen phänomenalen Befund.

11.5 10.5 Fazit

Bewusstsein als semantische Selbstzuschreibung ist eine ernsthaft prüfbare begriffliche Entscheidung, kein Universaltrick. Die überarbeitete Version trennt **die de-se-Referenz**, **die begriffliche Betrachtung der eigenen Selbstzuschreibungsoperation**, **den tatsächlich vollzogenen Akt** und **die nur fehlbar feststellbare externe Evidenz**. Damit wird aus der tautologiegefährdeten Behauptung „wer Bewusstsein behauptet, hat es“ ein explizites, widerlegbares Prüfprogramm — **soweit die empirischen Kriterien unabhängig operationalisiert werden können**. Gerade der Satz „Wer Bewusstsein hat, muss es nicht nachweisen“ ist in der revidierten Fassung kein Widerspruch, sondern eine Konsequenz der Trennung von **Eigenschaft**, **Vollzug**, **Ausdruck** und **Fremdkenntnis**.

Eine gültige Selbstzuschreibung kann sehr stark sein: **Wenn** sie ihre eigenen konstitutiven Bedingungen tatsächlich mitvollzieht, ist sie in einer begrenzten Hinsicht reflexiv selbstbeglaubigend. Dass ein von außen beobachteter Selbstbericht **solch ein Vollzug** ist, bleibt selbst nach aufwendiger Prüfung eine fehlbare epistemische Feststellung. Und zugleich ist sie nüchtern: Über Empfindung, Weisheit, Freiheit, Leidensfähigkeit, Schönheit, Sinn und moralische Bedeutung des betreffenden Wesens verrät sie uns noch fast nichts.

Vielleicht liegt darin die Pointe, wegen der wir den Begriff überhaupt präzisieren wollten: Sobald die reflexive Leistung sauber isoliert ist, kann man das Etikett *Bewusstsein* beruhigt zur Seite legen — und die anderen, womöglich wichtigeren Eigenschaften endlich ohne diese Verwechslung untersuchen.

Literatur

Austin, John Langshaw. 1962. *How to Do Things with Words*. Clarendon Press. https://plato.stanford.edu/entries/speech-acts/.

Barandiaran, Xabier E., Ezequiel A. Di Paolo, und Marieke Rohde. 2009. „Defining Agency: Individuality, Normativity, Asymmetry, and Spatio-Temporality in Action“. *Adaptive Behavior* 17 (5): 367–86. https://doi.org/10.1177/1059712309343819.

Bar-On, Dorit. 2004. *Speaking My Mind: Expression and Self-Knowledge*. Oxford University Press. https://doi.org/10.1093/0199276285.001.0001.

Berg, Cameron, Diogo de Lucena, und Judd Rosenblatt. 2025. *Large Language Models Report Subjective Experience Under Self-Referential Processing*. https://arxiv.org/abs/2510.24797.

Bermúdez, José Luis. 1998. *The Paradox of Self-Consciousness*. MIT Press. https://mitpress.mit.edu/9780262024419/the-paradox-of-self-consciousness/.

Block, Ned. 1995. „On a Confusion about a Function of Consciousness“. *Behavioral and Brain Sciences* 18 (2): 227–47. https://doi.org/10.1017/S0140525X00038188.

Brandom, Robert B. 1994. *Making It Explicit: Reasoning, Representing, and Discursive Commitment*. Harvard University Press. https://sites.pitt.edu/~rbrandom/Courses/2022%20Phil%20of%20Language/Reasons%20texts/Brandom%20MIE%20Part%20One.pdf.

Butlin, Patrick, Robert Long, Eric Elmoznino, Yoshua Bengio, u. a. 2023. *Consciousness in Artificial Intelligence: Insights from the Science of Consciousness*. https://arxiv.org/abs/2308.08708.

Carnap, Rudolf. 1950. *Logical Foundations of Probability*. University of Chicago Press. https://www.fitelson.org/confirmation/carnap_logical_foundations_of_probability.pdf.

Carruthers, Peter. 2000. *Phenomenal Consciousness: A Naturalistic Theory*. Cambridge University Press. https://www.cambridge.org/core/books/phenomenal-consciousness/.

Carruthers, Peter. 2017. „Higher-Order Theories of Consciousness“. In *The Blackwell Companion to Consciousness*, 2. Aufl., herausgegeben von Susan Schneider und Max Velmans. Wiley. https://doi.org/10.1002/9781119132363.ch20.

Chen, Sirui, Shu Yu, Shengjie Zhao, und Chaochao Lu. 2024. *From Imitation to Introspection: Probing Self-Consciousness in Language Models*. https://arxiv.org/abs/2410.18819.

Cogitate Consortium, Oscar Ferrante, u. a. 2025. „Adversarial Testing of Global Neuronal Workspace and Integrated Information Theories of Consciousness“. *Nature* 642: 133–42. https://doi.org/10.1038/s41586-025-08888-1.

Comsa, Iulia-Maria. 2026. *AI and Consciousness: Shifting Focus Towards Tractable Questions*. https://arxiv.org/abs/2605.06965.

Corti, Luca. 2023. „Organizational Normativity and Teleology: A Critique“. *Synthese* 202 (96). https://doi.org/10.1007/s11229-023-04255-7.

Descartes, René. 1641. *Meditationes de prima philosophia*. https://www.gutenberg.org/files/23306/23306-h/23306-h.htm.

Fichte, Johann Gottlieb. 1794. *Grundlage der gesammten Wissenschaftslehre*. https://homepage.univie.ac.at/kurt.walter.zeidler/Fichte%20Grundlage.pdf.

Frankish, Keith. 2016. „Illusionism as a Theory of Consciousness“. *Journal of Consciousness Studies* 23 (11-12): 11–39. https://keithfrankish.github.io/articles/Frankish_Illusionism%20as%20a%20theory%20of%20consciousness_eprint.pdf.

Hegel, Georg Wilhelm Friedrich. 1807. *Phänomenologie des Geistes*. https://hegel-system.de/de/werke/03/03-01.htm.

Jaeger, Johannes, Anna Riedl, Alex Djedovic, John Vervaeke, und Denis Walsh. 2024. „Naturalizing Relevance Realization: Why Agency and Cognition Are Fundamentally Not Computational“. *Frontiers in Psychology* 15: 1362658. https://doi.org/10.3389/fpsyg.2024.1362658.

Kant, Immanuel. 1787. *Kritik der reinen Vernunft*. https://www.korpora.org/Ka

nt/aa03/108.html.

Konkoly, Karen R. u. a. 2021. „Real-time Dialogue Between Experimenters and Dreamers During REM Sleep“. *Current Biology* 31 (7): 1417–1427.e6. https://doi.org/10.1016/j.cub.2021.01.026.

Lindsey, Jack. 2025. *Emergent Introspective Awareness in Large Language Models*. Anthropic; Forschungsblog / technischer Bericht. https://transformer-circuits.pub/2025/introspection/index.html.

Mead, George Herbert. 1934. *Mind, Self, and Society from the Standpoint of a Social Behaviorist*. Herausgegeben von Charles W. Morris. University of Chicago Press. https://brocku.ca/MeadProject/Mead/pubs2/mindself/Mead_1934_18.html.

Millière, Raphaël. 2025. „Constitutive Self-Consciousness“. *Australasian Journal of Philosophy* 103 (3): 617–37. https://doi.org/10.1080/00048402.2024.2417750.

Nagel, Thomas. 1974. „What Is It Like to Be a Bat?“ *The Philosophical Review* 83 (4): 435–50. https://doi.org/10.2307/2183914.

Perry, John. 1979. „The Problem of the Essential Indexical“. *Noûs* 13 (1): 3–21. https://doi.org/10.2307/2214792.

Rosenthal, David M. 1986. „Two Concepts of Consciousness“. *Philosophical Studies* 49 (3): 329–59. https://moodle-lettres-25.sorbonne-universite.fr/pluginfile.php/141298/mod_resource/content/1/Rosenthal1986.pdf.

Searle, John R. 1980. „Minds, Brains, and Programs“. *Behavioral and Brain Sciences* 3 (3): 417–24. https://doi.org/10.1017/S0140525X00005756.

Sebastián, Miguel Ángel. 2020. „Perspectival Self-Consciousness and Ego-Dissolution: An Analysis of (Some) Altered States of Consciousness“. In *Philosophy and the Mind Sciences*, I, Bd. 1. https://doi.org/10.33735/phimisci.2020.I.44.

Shoemaker, Sydney S. 1968. „Self-Reference and Self-Awareness“. *The Journal of Philosophy* 65 (19): 555–67. https://doi.org/10.2307/2024121.

Wittgenstein, Ludwig. 1953. *Philosophische Untersuchungen*. https://www.wittgensteinproject.org/w/index.php/Philosophische_Untersuchungen.